

Ályktanir fyrir flokkabreytur

Tölfræði frá grunni

Anna Helga Jónsdóttir og Sigrún Helga Lund

Háskóli Íslands



HÁSKÓLI ÍSLANDS

Helstu atriði:

- 1 Ályktanir um hlutfall þýðis
- 2 Ályktanir um hlutföll tveggja þýða
- 3 Ályktanir um hlutföll fleiri þýða
- 4 Tengslatöflur

Yfirlit

- 1 Ályktanir um hlutfall þýðis
- 2 Ályktanir um hlutföll tveggja þýða
- 3 Ályktanir um hlutföll fleiri þýða
- 4 Tengslatöflur

Mat á þýðishlutfalli

- ▶ Algeng leið til að draga ályktanir um flokkabreytu, er að skoða **hlutfall** mælinga þegar flokkabreytan tekur ákveðið gildi.
- ▶ Við látum p lýsa þessu hlutfalli fyrir **allt þýðið**.
- ▶ Við látum \hat{p} lýsa þessu hlutfalli fyrir **úrtakið okkar**.
- ▶ Við viljum nota mælingarnar okkar til að draga ályktanir um þýðishlutfallið p :
 - ▶ Með því að reikna öryggisbil fyrir \hat{p} .
 - ▶ Með því að framkvæma tilgátupróf um p .

Bernoulli tilraun og tvíkostadreifing

Bernoulli tilraun

Sérhver tilraun í safni endurtekinna tilrauna flokkast sem **Bernoulli tilraun** ef eftirfarandi gildir:

1. Hver tilraun hefur aðeins tvær mögulegar útkomur.
2. Líkurnar á jákvæðri útkomu eru þær sömu í hverri tilraun fyrir sig.
3. Útkomurnar eru óháðar.

Fjöldi jákvæðra tilrauna úr n Bernoulli tilraunum fylgir **tvíkostadreifingu** með stíkana n og p , skrifað $X \sim B(n, p)$, þar sem p eru líkurnar á jákvæðri útkomu.

Mat á þýðishlutfalli

Við metum þýðishlutfallið p , með úrtakshlutfallinu, þ.e.

$$\hat{p} = \frac{x}{n}$$

þar sem x er fjöldi þeirra mælinga sem hljóta viðkomandi útkomu og n er stærð úrtaksins.

Normalnálgun

- ▶ Þegar ákveðið skilyrði eru uppfyllt, líkist tvíkostadreifingin normaldreifingunni.
- ▶ Þá er hægt að nota aðferðir sem byggjast á eiginleikum normaldreifingarinnar til að draga ályktanir um slembistærðir sem í raun fylgja tvíkostadreifingu.
- ▶ Það köllum við að beita **normalnálgun**.

Hvenær má nota normalnálgun?

Séu $n\hat{p}$ og $n(1 - \hat{p})$ stærri en 15 má nota normalnálgun til að draga ályktanir um hlutfall tvíkostadreifingar.

Öryggisbil

Öryggisbil fyrir hlutfall þýðis

Séu skilyrðin fyrir að nota normalnálgunina uppfyllt má reikna neðra öryggismark fyrir p með:

$$\hat{p} - z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

og efra öryggismarkið með

$$\hat{p} + z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

þar sem $\hat{p} = \frac{x}{n}$ og $z_{1-\alpha/2}$ fæst með að fletta upp í töflu stöðluðu normaldreifingarinnar.

Núlltilgátan

- ▶ Tilgátuprófið í þessum hluta prófar núlltilgátuna hvort hlutfall þýðisins, p , sé jafnt einhverju ákveðnu gildi sem við köllum p_0 .
- ▶ Núlltilgátuna ritum við $H_0 : p = p_0$.
- ▶ Sé prófið tvíhliða drögum við þá ályktun að hlutfallið p sé frábrugðið p_0 .
- ▶ Sé það einhliða getum við fullyrt að p sé annað hvort stærra eða minna en p_0 eftir því sem við á.

Tilgátupróf fyrir hlutfall þýðis

Tilgátupróf fyrir hlutfall þýðis

Séu skilyrðin fyrir að nota normalnálgunina uppfyllt má nota eftirfarandi tilgátupróf:

Núlltilgátan er:

$$H_0 : p = p_0$$

Prófstærðin er:

$$Z = \frac{X - np_0}{\sqrt{np_0(1 - p_0)}}$$

þar sem X er fjöldi heppnaðra tilrauna og n er stærð úrtaksins.

Ef núlltilgátan er sönn fylgir prófstærðin stöðluðu normaldreifingunni, eða $Z \sim N(0, 1)$.

Gagntilgátur fyrir hlutfall þýðis

Gagntilgátur fyrir hlutfall þýðis

Gagntilgátan getur verið einhliða eða tvíhliða og má sjá þær ásamt höfnunarsvæðunum hér að neðan.

Gagntilgáta	Hafna H_0 ef:
$H_1 : p < p_0$	$Z < -z_{1-\alpha}$
$H_1 : p > p_0$	$Z > z_{1-\alpha}$
$H_1 : p \neq p_0$	$Z < -z_{1-\alpha/2}$ eða $Z > z_{1-\alpha/2}$

Hlutfall þýðis - Dæmi

Kolbeinn Tumi vill kanna hvort meirihluti landsmanna styður ríkisstjórnina. Hvaða núlltilgátu ætti hann að nota fyrir tilgátuprófið sitt?

Hlutfall þýðis - Dæmi

Kolbeinn Tumi vill kanna hvort meirihluti landsmanna styður ríkisstjórnina. Hvaða núlltilgátu ætti hann að nota fyrir tilgátuprófið sitt?

Hann ætti að nota núlltilgátuna: $H_0 : p = 0.5$.

Hlutfall þýðis - Dæmi

Kolbeinn Tumi vill kanna hvort meirihluti landsmanna styður ríkisstjórnina. Hvaða núlltilgátu ætti hann að nota fyrir tilgátuprófið sitt?

Hann ætti að nota núlltilgátuna: $H_0 : p = 0.5$.

Hann framkvæmir könnun þar sem $\hat{p} = 0.56$. Hann reiknar líka 95% öryggisbil fyrir hlutfallið og það reynist $(0.46, 0.66)$. Hvaða ályktun dregur Kolbeinn Tumi (miðað við $\alpha = 0.05$)?

Hlutfall þýðis - Dæmi

Kolbeinn Tumi vill kanna hvort meirihluti landsmanna styður ríkisstjórnina. Hvaða núlltilgátu ætti hann að nota fyrir tilgátuprófið sitt?

Hann ætti að nota núlltilgátuna: $H_0 : p = 0.5$.

Hann framkvæmir könnun þar sem $\hat{p} = 0.56$. Hann reiknar líka 95% öryggisbil fyrir hlutfallið og það reynist $(0.46, 0.66)$. Hvaða ályktun dregur Kolbeinn Tumi (miðað við $\alpha = 0.05$)?

Hlutlausu gildið $p = 0.5$ er inni á bilinu $(0.46, 0.66)$ svo Kolbeinn Tumi getur ekki hafnað núlltilgátunni og getur því ekki ályktað út frá tilgátuprófinu.

Yfirlit

- 1 Ályktanir um hlutfall þýðis
- 2 Ályktanir um hlutföll tveggja þýða
- 3 Ályktanir um hlutföll fleiri þýða
- 4 Tengslatöflur

Möt á hlutföllum í tveimur þýðum

- ▶ Við köllum hlutföllin í þýðunum tveimur p_1 og p_2 en hlutföll í tilsvarandi úrtökum \hat{p}_1 og \hat{p}_2 .
- ▶ Við prófum $\mathbf{H}_0 : \mathbf{p}_1 = \mathbf{p}_2$, en reiknum öryggisbil fyrir $\hat{\mathbf{p}}_1 - \hat{\mathbf{p}}_2$.
- ▶ Í þessu tilviki er ekki hægt að framkvæma próf sem byggir beint á tvíkostadreifingunni, heldur verðum við að nota normalnálgun.

Skilyrði fyrir normalnálgun

Beita má normalnálgun ef gera má ráð fyrir að $n_1\hat{p}_1$, $n_1(1 - \hat{p}_1)$, $n_2\hat{p}_2$ og $n_2(1 - \hat{p}_2)$ séu öll stærri en 15

Öryggisbil fyrir hlutföll tveggja þýða

Öryggisbil fyrir hlutföll tveggja þýða

Séu skilyrðin fyrir að nota normalnálgunina uppfyllt má reikna neðra öryggismark fyrir **muninn á** p_1 og p_2 með:

$$\hat{p}_1 - \hat{p}_2 - z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

og efra öryggismarkið með

$$\hat{p}_1 - \hat{p}_2 + z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

þar sem $\hat{p}_1 = \frac{x_1}{n_1}$, $\hat{p}_2 = \frac{x_2}{n_2}$ og $z_{1-\alpha/2}$ fæst með að fletta upp í töflu stöðluðu normaldreifingarinnar.

Tilgátupróf fyrir hlutföll tveggja þýða

Séu skilyrðin fyrir að nota normalnálgunina uppfyllt má nota eftirfarandi tilgátupróf:

Núlltilgátan er:

$$H_0 : p_1 = p_2$$

Prófstærðin er:

$$Z = \frac{\frac{X_1}{n_1} - \frac{X_2}{n_2}}{\sqrt{\hat{P}(1 - \hat{P}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}, \quad \text{þar sem} \quad \hat{P} = \frac{X_1 + X_2}{n_1 + n_2}$$

Ef núlltilgátan er sönn fylgir prófstærðin stöðluðu normaldreifingunni, eða $Z \sim N(0, 1)$.

Ályktanir um hlutföll tveggja þýða - Dæmi

Kristinn er að kanna hlutfall örvættra í úrvalsdeildum fótbolta á Íslandi. Hann vill athuga hvort hlutfall örvættra sé ólíkt hjá körlum og konum. Hvernig segjum við núlltilgátuna hans í orðum?

Ályktanir um hlutföll tveggja þýða - Dæmi

Kristinn er að kanna hlutfall örvfættra í úrvalsdeildum fótbolta á Íslandi. Hann vill athuga hvort hlutfall örvfættra sé ólíkt hjá körlum og konum. Hvernig segjum við núlltilgátuna hans í orðum?

Núlltilgátan hans er að hlutfall örvfættra karlmanna sé það sama og hlutfall örvfættra kvenmanna í úrvaldeildum fótbolta á Íslandi.

Ályktanir um hlutföll tveggja þýða - Dæmi

Kristinn er að kanna hlutfall örvfættra í úrvalsdeildum fótbolta á Íslandi. Hann vill athuga hvort hlutfall örvfættra sé ólíkt hjá körlum og konum. Hvernig segjum við núlltilgátuna hans í orðum?

Núlltilgátan hans er að hlutfall örvfættra karlmanna sé það sama og hlutfall örvfættra kvenmanna í úrvaldeildum fótbolta á Íslandi.

Í rannsókninni reyndust 11% karlmannanna og 9 % kvenmannanna vera örvfætt. Kristinn reiknaði 95% öryggisbil fyrir mismun hlutfallanna og reyndist það (0.01, 0.03). Hvaða ályktun dregur Kristinn? (miðað við $\alpha = 0.05$)?

Ályktanir um hlutföll tveggja þýða - Dæmi

Kristinn er að kanna hlutfall örvfættra í úrvalsdeildum fótbolta á Íslandi. Hann vill athuga hvort hlutfall örvfættra sé ólíkt hjá körlum og konum. Hvernig segjum við núlltilgátuna hans í orðum?

Núlltilgátan hans er að hlutfall örvfættra karlmanna sé það sama og hlutfall örvfættra kvenmanna í úrvaldeildum fótbolta á Íslandi.

Í rannsókninni reyndust 11% karlmannanna og 9 % kvenmannanna vera örvfætt. Kristinn reiknaði 95% öryggisbil fyrir mismun hlutfallanna og reyndist það (0.01, 0.03). Hvaða ályktun dregur Kristinn? (miðað við $\alpha = 0.05$)?

Hlutlausu tilvikið $p_1 = p_2$ er jafngilt því að $p_1 - p_2 = 0$. Gildið 0 er ekki á bilinu (0.01, 0.03) og því getur Kristinn áætlað að hlutfall örvfættra karlmanna sé hærra en hlutfall örvfættra kvenmanna.

Yfirlit

- 1 Ályktanir um hlutfall þýðis
- 2 Ályktanir um hlutföll tveggja þýða
- 3 Ályktanir um hlutföll fleiri þýða
- 4 Tengslatöflur

Kí-kvaðrat próf

- ▶ Tilgátuna úr síðasta hluta má útvíkka þannig að hægt sé að bera saman hlutföll fleiri en tveggja þýða.
- ▶ Þá er ekki lengur hægt að nota aðferðir byggðar á nálgun normaldreifingarinnar, heldur er stuðst við svokölluð kí-kvaðrat próf (χ^2 -próf).
- ▶ Aðferðina má einnig nota þegar bera á saman hlutföll tveggja þýða eins og í hlutanum hér að framan.
- ▶ Þá munu Kí-kvaðrat prófið og prófið sem byggir á normalnálgun alltaf gefa sömu niðurstöðuna.

Töflur fyrir kí-kvaðrat próf

Töflur fyrir kí-kvaðrat próf

Þegar framkvæma á kí-kvaðrat próf er gott að búa til þrjár töflur:

- ▶ Tafla mældrar tíðni: Inniheldur tíðni sem við fáum úr rannsókninni, mæld tíðni táknuð með o .
- ▶ Tafla væntanlegrar tíðni: Inniheldur væntanlega tíðni, táknuð með e . Gildin fást með því að margfalda samtalsölurnar úr töflu mældrar tíðni úr þeim dálki og þeirri línu sem við erum stödd í og deila með heildarfjölda. Allar tölur í þessari töflu verða að vera hærri en 5 annars er ekki hægt að nota prófið.
- ▶ Tafla prófstærðar: Inniheldur framlag til prófstærðar reiknað með $\frac{(o-e)^2}{e}$. Að lokum eru allar tölurnar í töflunni lagðar saman til að fá gildið á prófstærðinni (sjá næstu glæru).

Kí-kvaðrat próf fyrir hlutföll

Kí-kvaðrat próf fyrir hlutföll

Tilgáturnar eru:

$$H_0 : p_1 = p_2 = \dots = p_d$$

$$H_1 : \text{hlutföllin eru ekki öll jöfn}$$

Prófstærðin er:

$$\chi^2 = \sum_{i=1}^l \sum_{j=1}^d \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

þar sem l er fjöldi lína, d er fjöldi dálka, o er mæld tíðni og e er væntanleg tíðni.

Sé núlltilgátan sönn fylgir prófstærðin χ^2 -dreifingu með $(l - 1) \cdot (d - 1)$ fjölda frígráða. Hafna skal núlltilgátunni sé $\chi^2 > \chi^2_{1-\alpha, ((l-1) \cdot (d-1))}$.

Ályktanir um hlutföll fleiri þýða - Dæmi

Davíð kannar hvort fólk eigi happatölu og framkvæmir könnun í Reykjavík, í nágrannasveitarfélögum borgarinnar og svo á landsbyggðinni. Hann fær eftirfarandi niðurstöður:

	Reykjavík	Nágrannasv.	Landsbyggðin
Nei	450	332	415
Já	81	90	108

Reiknið töflu væntanlegrar tíðni, töflu prófstærðar og prófstærðina fyrir þessar niðurstöður.

Ályktanir um hlutföll fleiri þýða - Lausn

Byrjum á að reikna samtaltölurnar fyrir töflu mældrar tíðni.

Ályktanir um hlutföll fleiri þýða - Lausn

Byrjum á að reikna samtaltölurnar fyrir töflu mældrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin	Sum
Nei	450	332	415	1197
Já	81	90	108	279
Sum	531	422	523	1476

Ályktanir um hlutföll fleiri þýða - Lausn

Byrjum á að reikna samtaltölurnar fyrir töflu mældrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin	Sum
Nei	450	332	415	1197
Já	81	90	108	279
Sum	531	422	523	1476

Margföldum svo saman samtaltölurnar í hverri röð og dálki og deilum með heildarfjölda:

Ályktanir um hlutföll fleiri þýða - Lausn

Byrjum á að reikna samtaltölurnar fyrir töflu mældrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin	Sum
Nei	450	332	415	1197
Já	81	90	108	279
Sum	531	422	523	1476

Margföldum svo saman samtaltölurnar í hverri röð og dálki og deilum með heildarfjölda:

	Reykjavík	Nágrannasv.	Landsbyggðin
Nei	430.628	342.23171	424.14024
Já	100.372	79.76829	98.85976

Ályktanir um hlutföll fleiri þýða - Lausn

Reiknum svo töflu prófstærðar. Þá reiknum við $\frac{(o-e)^2}{e}$ fyrir hvern reit. o kemur úr töflu mældrar tíðni en e kemur úr töflu væntanlegrar tíðni.

Ályktanir um hlutföll fleiri þýða - Lausn

Reiknum svo töflu prófstærðar. Þá reiknum við $\frac{(o-e)^2}{e}$ fyrir hvern reit. o kemur úr töflu mældrar tíðni en e kemur úr töflu væntanlegrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin
Nei	0.8714539	0.3058975	0.1969727
Já	3.7388184	1.3123991	0.8450765

Ályktanir um hlutföll fleiri þýða - Lausn

Reiknum svo töflu prófstærðar. Þá reiknum við $\frac{(o-e)^2}{e}$ fyrir hvern reit. o kemur úr töflu mældrar tíðni en e kemur úr töflu væntanlegrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin
Nei	0.8714539	0.3058975	0.1969727
Já	3.7388184	1.3123991	0.8450765

Prófstærðin er svo summa þessara gilda:

Ályktanir um hlutföll fleiri þýða - Lausn

Reiknum svo töflu prófstærðar. Þá reiknum við $\frac{(o-e)^2}{e}$ fyrir hvern reit. o kemur úr töflu mældrar tíðni en e kemur úr töflu væntanlegrar tíðni.

	Reykjavík	Nágrannasv.	Landsbyggðin
Nei	0.8714539	0.3058975	0.1969727
Já	3.7388184	1.3123991	0.8450765

Prófstærðin er svo summa þessara gilda: 7.2706181

Yfirlit

- 1 Ályktanir um hlutfall þýðis
- 2 Ályktanir um hlutföll tveggja þýða
- 3 Ályktanir um hlutföll fleiri þýða
- 4 Tengslatöflur**

Tengslatöflur

- ▶ Við vorum að sjá hvernig við getum borið saman hlutföll í mismunandi þýðum.
- ▶ Við viljum enn oftast bera saman tvær flokkabreytur þar sem gögnum er aflað úr sama þýðinu.
- ▶ Til þess eru notaðar svokallaðar tengslatöflur og prófin ganga út á að svara spurningunni hvort breyturnar tvær séu óháðar.
- ▶ Prófstærðin sem notast er við er sú sama og áður og eru allir útreikningar því eins.
- ▶ Tilgáturarnar eru þó settar fram á annan máta.

Tengslatöflur

Tengslatöflur

- ▶ Gerum ráð fyrir að önnur breytan hafi l flokka, en hin d flokka.
- ▶ Tilgáturnar eru

H_0 : Það er ekki samband á milli breytanna tveggja

H_1 : Það er samband á milli breytanna tveggja

- ▶ Prófstærðin er summa allra gildanna í töflu prófstærðar.
- ▶ Sé núlltilgátan sönn fylgir prófstærðin χ^2 -dreifingu með $(l - 1) \cdot (d - 1)$ frígráður.
- ▶ Hafna skal núlltilgátunni sé $\chi^2 > \chi^2_{1-\alpha, ((l-1) \cdot (d-1))}$.

Tengslatölur - Dæmi

Pröstur kannar samband milli hjúskaparstöðu og starfsstéttar. Hann fær eftirfarandi niðurstöður:

	Einhleyp	Sambúð	Gift	Skilin
Stjórnendur	50	92	316	40
Iðnaðarmenn	20	46	139	13
Þjónustustörf	31	40	91	29
Verkafólk	17	24	55	11

Hann framkvæmir kí-kvaðratpróf og fær prófstærðina 26.97304.
Hvaða ályktun dregur hann?

Tengslatölur - Dæmi

Pröstur kannar samband milli hjúskaparstöðu og starfsstéttar. Hann fær eftirfarandi niðurstöður:

	Einhleyp	Sambúð	Gift	Skilin
Stjórnendur	50	92	316	40
Iðnaðarmenn	20	46	139	13
Þjónustustörf	31	40	91	29
Verkafólk	17	24	55	11

Hann framkvæmir kí-kvaðratpróf og fær prófstærðina 26.97304. Hvaða ályktun dregur hann?

Hér eru 4 dálkar og 4 línur, svo við miðum við

$$\chi^2_{0.95,((4-1) \cdot (4-1))} = \chi^2_{0.95,(3 \cdot 3)} = \chi^2_{0.95,(9)} = 16.92.$$

Tengslatölur - Dæmi

Pröstur kannar samband milli hjúskaparstöðu og starfsstéttar. Hann fær eftirfarandi niðurstöður:

	Einhleyp	Sambúð	Gift	Skilin
Stjórnendur	50	92	316	40
Iðnaðarmenn	20	46	139	13
Þjónustustörf	31	40	91	29
Verkafólk	17	24	55	11

Hann framkvæmir kí-kvaðratpróf og fær prófstærðina 26.97304. Hvaða ályktun dregur hann?

Hér eru 4 dálkar og 4 línur, svo við miðum við

$$\chi^2_{0.95,((4-1) \cdot (4-1))} = \chi^2_{0.95,(3 \cdot 3)} = \chi^2_{0.95,(9)} = 16.92.$$

Prófstærðin okkar er stærri en 16.92 svo við ályktum að það sé samband á milli hjúskaparstöðu og starfsstéttar.