# Línuleg aðhvarfsgreining Tölfræði frá grunni

Anna Helga Jónsdóttir og Sigrún Helga Lund

Háskóli Íslands



#### Helstu atriði:

- Einfalt línulegt aðhvarf hluti 1
- Einfalt línulegt aðhvarf hluti 2
- 3 Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

## Hvert erum við komin...

- Einfalt línulegt aðhvarf hluti 1
- 2 Einfalt línulegt aðhvarf hluti 2
- Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

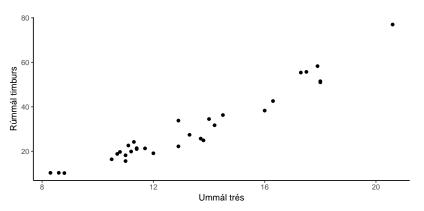
# Línuleg aðhvarfsgreining

- Línuleg aðhvarfsgreining er ein algengasta tölfræðiaðferð sem notuð er til að kanna samband tveggja talnabreyta.
- Við gerum ráð fyrir að lýsa megi sambandi breytanna með jöfnu beinnar línu.
- Línuleg aðhvarfsgreining er sér í lagi mikið notuð þegar önnur breytan er svarbreyta og hin skýribreyta.
- Utvíkka má línulega aðhvarfsgreiningu þannig að nota megi fleiri en eina skýribreytu, sem geta hvort heldur sem er verið flokkabreytur eða talnabreytur.
- Við ætlum þó bara að skoða tilvikið þegar það er einungis ein talnabreyta sem skýribreyta.

# Línuleg aðhvarfsgreining

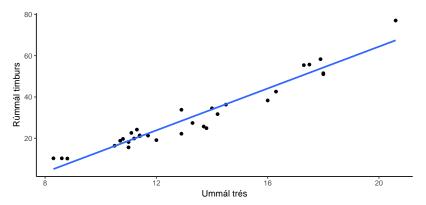
- ▶ Í einföldu línulegu aðhvarfi göngum við út frá því að það sé engin óvissa í mælingum okkar á skýribreytunni.
- Þetta er oft orðað þannig að skýribreytan sé föst.
- Svarbreytan er hins vegar slembin og er dreifing hennar er háð skýribreytunni.
- Við notum Y til að tákna svarbreytuna og x til að tákna skýribreytuna.

# Samband ummáls trés og rúmmáls timbursins sem það gaf



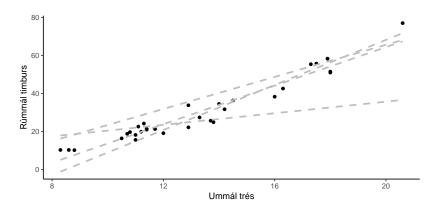
Fyrsta skref í línulegri aðhvarfsgreiningu ætti alltaf að vera að teikna gögnin.

## Er hægt að lýsa sambandinu með jöfnu beinnar línu?



Er línulegt samband á milli ummáls trés og rúmmáls þess timbur sem það gefur af sér?

# Hvernig veljum við línuna?



# Aðhvarfsgreiningarlíkanið

## Aðhvarfsgreiningarlíkanið

Einfalda aðhvarfsgreiningarlíkanið (simple linear regression model) má skrifa sem

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

þar sem  $\beta_0$  og  $\beta_1$  eru óþekktir stikar og  $\varepsilon$  er normaldreifð slembistærð með meðaltal 0.

Markmið einfalds línulegs aðhvarfs er fyrst og fremst að meta stuðlana  $\beta_0$  og  $\beta_1$  með mælingunum á breytunum tveimur, x og Y.

Aðferðin sem við notum kallast aðferð minnstu kvaðrata.

## Jafna aðhvarfslínu minnstu kvaðrata

#### Jafna aðhvarfslínu minnstu kvaðrata

Táknum meðaltal og staðalfrávik x breytunnar með  $\bar{x}$  og  $s_x$  og y breytunnar með  $\bar{y}$  og  $s_y$  og fylgnina á milli þeirra með r.

Við metum hallatölu línunnar með

$$b_1 = r \frac{s_y}{s_x}$$

og skurðpunktinn með

$$b_0 = \bar{y} - b_1 \bar{x}$$
.

Pá er jafna aðhvarfslínu minnstu kvaðrata

$$\hat{y} = b_0 + b_1 x$$

Smíðum aðhvarfslíkan til að meta hversu mikið rúmmál timburs færst af tré með tiltekið ummál. Gefum okkur að eftirfarandi lýsistærðir hafi verið reiknaðar út:

Smíðum aðhvarfslíkan til að meta hversu mikið rúmmál timburs færst af tré með tiltekið ummál. Gefum okkur að eftirfarandi lýsistærðir hafi verið reiknaðar út:

$$b_1 = r \frac{s_y}{s_x} =$$

Smíðum aðhvarfslíkan til að meta hversu mikið rúmmál timburs færst af tré með tiltekið ummál. Gefum okkur að eftirfarandi lýsistærðir hafi verið reiknaðar út:

$$b_1 = r \frac{s_y}{s_x} = 0.97 \cdot \frac{16.48}{3.18} = 5.03$$

Smíðum aðhvarfslíkan til að meta hversu mikið rúmmál timburs færst af tré með tiltekið ummál. Gefum okkur að eftirfarandi lýsistærðir hafi verið reiknaðar út:

$$b_1 = r \frac{s_y}{s_x} = 0.97 \cdot \frac{16.48}{3.18} = 5.03$$
  
 $b_0 = \bar{y} - b_1 \bar{x} =$ 

Smíðum aðhvarfslíkan til að meta hversu mikið rúmmál timburs færst af tré með tiltekið ummál. Gefum okkur að eftirfarandi lýsistærðir hafi verið reiknaðar út:

Meðaltal ummáls = 13.25 tommur Staðalfrávik ummáls = 3.18 tommur Meðaltal rúmmáls = 30.17 tommur Staðalfrávik rúmmáls = 16.48 tommur Fylgni ummáls og rúmmáls = 0.97 tommur.

$$b_1 = r \frac{s_y}{s_x} = 0.97 \cdot \frac{16.48}{3.18} = 5.03$$
  

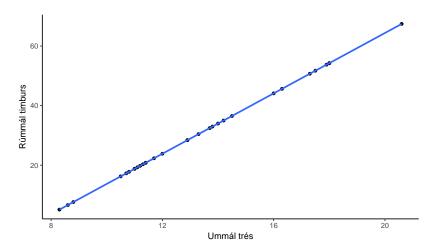
$$b_0 = \bar{y} - b_1 \bar{x} = 30.17 - 5.03 \cdot 13.25 = -36.48$$

Pá er jafnan  $\hat{y} = -36.48 + 5.03 \cdot x$ 

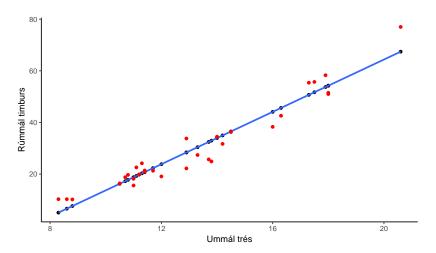
## Hvert erum við komin...

- Einfalt línulegt aðhvarf hluti 1
- Einfalt línulegt aðhvarf hluti 2
- Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

# Ef það væri engin óvissa...



## Raunveruleikinn!



14/45

#### Leifar

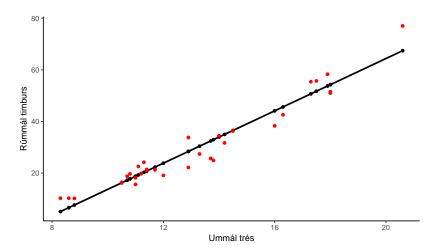
#### Leifar

Lóðrétta fjarlægðin frá mælingunum okkar að aðhvarfslínunni köllum við leifar og táknum með e. Stærð leifa má reikna með

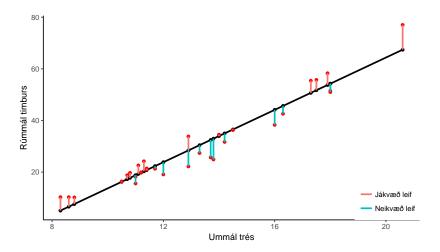
$$e_i = y_i - \hat{y}_i.$$

Punktar ofan aðhvarfslínunnar hafa jákvæða leif en punktar neðan hennar neikvæða.

## Leifar

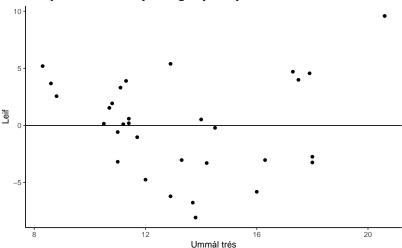


## Leifar



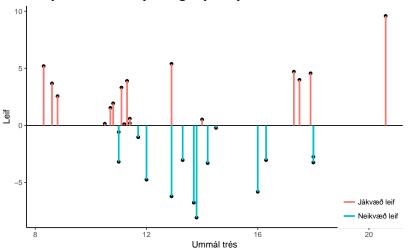
### Leifarit

Leifarit sýnir leifarnar á y-ás og skýribreytuna á x-ásnum.



#### Leifarit

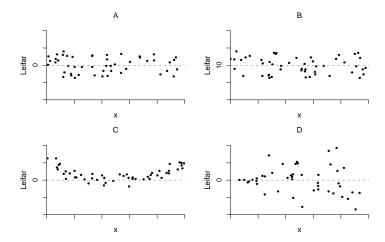
Leifarit sýnir leifarnar á y-ás og skýribreytuna á x-ásnum.



#### Forsendur líkansins

- Þegar við framkvæmum línulega aðhvarfsgreiningu gerum við ráð fyrir því að leifar líkansins séu óháðar og fylgi sömu normaldreifingunni.
- Með leifariti getum við kannað hvort leifarnar virðast óháðar (hvort það virðist ekki vera nein regla í þeim).
- Þá reynum við að passa að það sé ekkert mynstur í leifunum og að breytileikinn sé óháður skýribreytunni.
- ▶ Með normaldreifingarriti (kafla 5.4.1) getum við svo kannað hvort að dreifing leifanna svipi til normaldreifingar.

# Engin regla á að vera í leifariti!



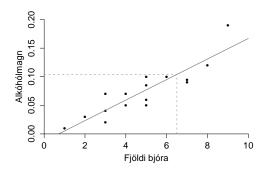
## Hvert erum við komin...

- Einfalt línulegt aðhvarf hluti :
- 2 Einfalt línulegt aðhvarf hluti 2
- 3 Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

## Brúun

#### Brúun

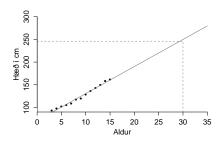
Sé aðhvarfslíkan notuð til að spá fyrir um gildi á Y fyrir eitthvert gildi á x sem er á sama reki og x-gildin sem notuð voru til að meta stikana í líkaninu er talað um að brúa (interpolate).



## Bryggjun

## Bryggjun

Sé aðhvarfslíkan notað til að spá fyrir um gildi á Y fyrir eitthvert gildi á x sem er **fjarri** þeim x-gildum sem notuð voru til að meta stikana í líkaninu er talað um að bryggja (exrapolate). Þetta svarar til að lengja aðhvarfslínuna. Það getur verið mjög vafasamt að bryggja!



# Skýringarhlutfall

## Skýringarhlutfall í einföldu línulegu aðhvarfi

Sé fylgnistuðullinn settur í annað veldi,  $r^2$ , er talað um skýringarhlutfall. Oft er notaður stór bókstafur fyrir skýringarhlutfallið, þ.e.  $R^2$ .

 $r^2$  stendur fyrir hlutfallslegan breytileika í Y sem er hægt að skýra með breytingum á x.

 $r^2$  getur í minnsta lagi verið 0, en í mesta lagi 1.

Hugsum okkur að það sé línulegt orsakasamband milli BMI stuðuls og blóðþrýstings.

▶ Hvor breytan ætti að vera x- breytan og hvor ætti að vera Y-breytan?

Hugsum okkur að það sé línulegt orsakasamband milli BMI stuðuls og blóðþrýstings.

► Hvor breytan ætti að vera x- breytan og hvor ætti að vera Y-breytan?

BMI stuðull ætti að vera skýribreytan (x-breytan) og blóðþrýstingur ætti að vera svarbreytan (Y-breytan).

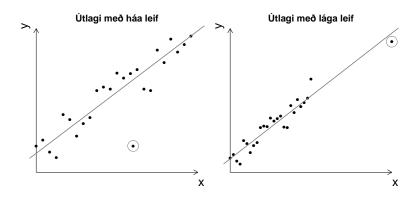
Hugsum okkur að það sé línulegt orsakasamband milli BMI stuðuls og blóðþrýstings.

- ► Hvor breytan ætti að vera x- breytan og hvor ætti að vera Y-breytan?
  - BMI stuðull ætti að vera skýribreytan (x-breytan) og blóðþrýstingur ætti að vera svarbreytan (Y-breytan).
- Fylgnin mældist 0.8. Hversu hátt hlutfall breytileika í blóðþrýstingi milli einstaklinga má þá útskýra með ólíku BMI?

Hugsum okkur að það sé línulegt orsakasamband milli BMI stuðuls og blóðþrýstings.

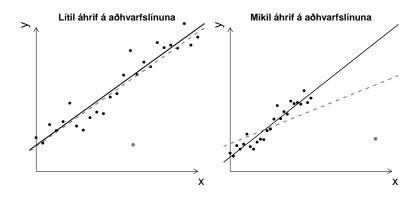
- ► Hvor breytan ætti að vera x- breytan og hvor ætti að vera Y-breytan?
  - BMI stuðull ætti að vera skýribreytan (x-breytan) og blóðþrýstingur ætti að vera svarbreytan (Y-breytan).
- Fylgnin mældist 0.8. Hversu hátt hlutfall breytileika í blóðþrýstingi milli einstaklinga má þá útskýra með ólíku BMI? Skýringarhlutfallið er  $0.8^2=0.64$ .
  - Pað þýðir að 64% breytileika í blóðþrýstingi mátti útskýra með breytileika í BMI.

# Útlagar og áhrifamikil mæligildi



Mynd: Útlagar og leifar þeirra.

# Útlagar og áhrifamikil mæligildi



Mynd: Áhrifamikil mæligildi.

# Meðhöndlun útlaga og áhrifamikilla mæligilda

- Það á alltaf að skoða útlaga og áhrifamikil mæligildi sérstaklega.
- ► Ef mistök hafa átt sér stað skal fjarlæga mæligildið úr safninu.
- Ef ekki er hægt að sýna fram á að um mistök hafi verið að ræða er oft gott að sýna útreikninga með og án þessara gilda.
- Í sumum tilfellum er eðlilegast að byggja útreikninga á mælisafninu án útlaga/áhrifamikilla mæligilda.
- Í þeim tilfellum verður að taka fram að líkanið gildi ekki fyrir mæligildi utan þess ramma mæligilda sem notuð voru við gerð líkansins.

#### Hvert erum við komin...

- Einfalt línulegt aðhvarf hluti :
- Einfalt línulegt aðhvarf hluti 2
- Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

# Ályktanir í aðhvarfsgreiningu

- Nú er kominn tími til að setja aðhvarfsgreiningu í samhengi við það sem við höfum áður lært um ályktunartölfræði.
- Mælingarnar okkar eru einhverri slembni háðar og því getum við fengið aðrar niðurstöður ef við endurtökum tilraunina og þar af leiðandi annað mat á aðhvarfslínunni okkar.
- Því er eðlilegt að reikna öryggisbil og tilgátupróf í einföldu línulegu aðhvarfi líkt og þið hafið séð svo mörg dæmi um hingað til.

## Aðhvarfsgreiningarlíkanið

Ef við gerum ráð fyrir að við höfum n paraðar mælingar  $(x_1,y_1),\ldots,(x_n,y_n)$ , má skrifa líkanið sem

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i.$$

- β<sub>0</sub> er hinn sanni skurðpunktur sem við ekki þekkjum, þýðisskurðpunkturinn.
- $\triangleright$   $\beta_1$  hin sanna hallatala, þýðishallatalan.
- $ightharpoonup \epsilon_i$  eru frávikin.

 $\beta_0$  og  $\beta_1$  eru því lýsistærðir, sem við viljum bæði meta og draga ályktanir um.

Það gerum við með því að beita aðferð minnstu kvaðrata á gögnin okkar.

#### Slembistærðin $\varepsilon$

arepsilon til að lýsir þeirri óvissu sem er til staðar í mælingum okkar á Y.

Við gerum ráð fyrir að  $\varepsilon_i$  séu einsdreifðar óháðar slembistærðir sem fylgja normaldreifingu með meðaltal 0 og dreifni  $\sigma^2$ .

#### Mat á $\sigma^2$ í einföldu línulegu aðhvarfi

Mat á  $\sigma^2$  í einföldu línulegu aðhvarfi táknum við með  $s_e^2$  og reiknum með

$$s_e^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n-2}.$$

Petta er sama og jafna og fyrir "venjulega" staðalfrávikið, nema nú er deilt með n-2 en ekki n-1.

## Öryggisbil fyrir $\beta_0$

## Öryggisbil fyrir $\beta_0$

Neðra mark  $1 - \alpha$  öryggisbils fyrir  $\beta_0$  er:

$$b_0 - t_{1-\alpha/2,(n-2)} \cdot s_e \sqrt{\frac{1}{n} + \frac{(\bar{x})^2}{s_x^2 \cdot (n-1)}}$$

Efra mark  $1 - \alpha$  öryggisbils er:

$$b_0 + t_{1-\alpha/2,(n-2)} \cdot s_e \sqrt{\frac{1}{n} + \frac{(\bar{x})^2}{s_x^2 \cdot (n-1)}}$$

þar sem  $b_0$  er reiknað skv. jöfnu, n er fjöldi paraðra mælinga,  $\bar{x}$  er meðaltal skýribreytunnar,  $s_x$  er staðalfrávik skýribreytunnar og  $t_{1-\alpha/2,(n-2)}$  má finna í t-töflu.

# Öryggisbil fyrir $\beta_1$

#### Öryggisbil fyrir $\beta_1$

Neðra mark  $1 - \alpha$  öryggisbils fyrir  $\beta_1$  er:

$$b_1 - t_{1-\alpha/2,(n-2)} \cdot s_e \frac{1}{\sqrt{s_x^2 \cdot (n-1)}}$$

Efra mark  $1 - \alpha$  öryggisbils er:

$$b_1 + t_{1-\alpha/2,(n-2)} \cdot s_e \frac{1}{\sqrt{s_x^2 \cdot (n-1)}}$$

þar sem  $b_1$  er reiknað skv. jöfnu, n er fjöldi paraðra mælinga,  $s_x$  er staðalfrávik skýribreytunnar og  $t_{1-\alpha/2,(n-2)}$  má finna í t-töflu.

## Spábil fyrir framtíðarmælingar

## Spábil fyrir framtíðarmælingar

Neðra mark  $1 - \alpha$  spábils fyrir framtíðarmælingu á Y:

$$(b_0 + b_1 x_0) - t_{1-\alpha/2,(n-2)} \cdot s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_x^2(n-1)}}$$

Efra mark  $1 - \alpha$  spábils er:

$$(b_0 + b_1 x_0) + t_{1-\alpha/2,(n-2)} \cdot s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_x^2(n-1)}}$$

þar sem  $b_0$  og  $b_1$ , má reikna skv. jöfnum, n er fjöldi paraðra mælinga,  $\bar{x}$  er meðaltal skýribreytunnar,  $s_x$  er staðalfrávik skýribreytunnar og  $t_{1-\alpha/2,(n-2)}$  má finna í t-töflu.

# Próf á fylgnistuðli

#### Tilgátupróf fyrir $\rho$

Núlltilgátan er:

$$H_0: \rho = 0$$

Prófstærðin er:

$$T = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

Ef núlltilgátan er sönn fylgir prófstærðin t-dreifingu með n-2 frígráður, eða  $T \sim t(n-2)$ .

Gagntilgáta	Hafna $H_0$ ef:	
$H_1: \rho < 0$	$T < -t_{1-\alpha}$	
$H_1: \rho > 0$	$T > t_{1-\alpha}$	
$H_1: \rho \neq 0$	$T<-t_{1-lpha/2}$ eða $T>t_{lpha/2}$	

#### Hvert erum við komin...

- Einfalt línulegt aðhvarf hluti :
- 2 Einfalt línulegt aðhvarf hluti 2
- ③ Einfalt línulegt aðhvarf hluti 3
- Ályktanir í aðhvarfsgreiningu
- 5 Fervikagreining í aðhvarfsgreiningu

- Nota má fervikagreiningu til að draga ályktanir í línulegri aðhvarfgreiningu.
- Uppsetningin er á margan hátt svipuð og þegar við notum fervikagreiningu til að draga ályktanir um meðaltöl, en fervikasummurnar eru reiknaðar á örlítið annan hátt.

Fyrir sérhverja mælingu  $y_i$  gildir að

$$(y_i - \bar{y}_.) = (\hat{y}_i - \bar{y}_.) + (y_i - \hat{y}_i)$$

þar sem  $\bar{y}_{\cdot}$  er meðaltal y-mælinganna og  $\hat{y}_{i}$  er spágildið fyrir  $y_{i}$ .

Þegar aðhvarfsgreiningarlíkan er metið með jöfnu minnstu kvaðrata gildir ennfremur að

$$\sum_{i=1}^{n} (y_i - \bar{y}_i)^2 = \sum_{i=1}^{n} (\hat{y}_i - \bar{y}_i)^2 + \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Út frá þessu reiknum við fervikasummur í einföldu línulegu aðhvarfi.

### Fervikasummur í einföldu línulegu aðhvarfi

Fervikasummurnar eru reiknaðar með

$$SS_{T} = \sum_{i=1}^{n} (y_{i} - \bar{y}_{.})^{2}$$

$$SS_{R} = \sum_{i=1}^{n} (\hat{y}_{i} - \bar{y}_{.})^{2}$$

$$SS_{E} = \sum_{i=1}^{n} (y_{i} - \hat{y}_{i})^{2}$$

Heildarbreytileikanum má skipta upp í breytileika metnu gildanna annars vegar og breytileika leifanna hins vegar eða

$$SS_T = SS_R + SS_E.$$

Líkt og í fervikagreiningu er algengt er að setja kvaðratsummurnar upp í svokallaða *fervikagreiningartöflu* (ANOVA table). Dæmigerða fervikasummutöflu má sjá hér að neðan.

Fervikasummur	Frígráður	Meðalfervikasummur
$SS_R$	1	$MS_R = SS_R$
$SS_E$	N-2	$MS_E = \frac{SS_E}{N-2}$
$SS_T$	N-1	

Fervikasummurnar má einnig nota til að reikna skýringarhlutfall með öðrum hætti. Sú framsetning útskýrir jafnvel enn betur hvers vegna  $r^2$  stendur fyrir hlutfallslegan breytileika í Y sem er hægt að skýra með breytingum á x.

#### Skýringarhlutfall

Skýringarhlutfall má reikna með jöfnunni

$$r^2 = \frac{SSR}{SST}$$

Pað stendur fyrir hlutfallslegan breytileika í Y sem er hægt að skýra með breytingum á x.

## Tilgátupróf í fervikagreiningu fyrir aðhvarfsgreiningu

Tilgátuprófið sem við notum í fervikagreiningu gerir ráð fyrir að frávikin frá aðhvarfslínunni séu i.i.d. normaldreifð. Það skilyrði má kanna með því að teikna normaldreifingarrit af leifunum.

#### Tilgátupróf í fervikagreiningu fyrir aðhvarfsgreiningu

Tilgátan sem við viljum kanna er

$$H_0: \beta_1 = 0$$

á móti gagntilgátunni

$$H_1:\beta_1\neq 0$$

## Tilgátupróf í fervikagreiningu fyrir aðhvarfsgreiningu

#### Tilgátupróf fyrir einhliða fervikagreiningu, áframhald

Prófstærðin er

$$F = \frac{SS_R/(1)}{SS_E/(N-2)} = \frac{MS_R}{MS_E}.$$

Sé núlltilgátan sönn fylgir prófstærðin F-dreifingu með 1 og N-2 fjölda fríráða, eða  $F\sim F_{(1,N-2)}$ , þar sem N er heildarfjöldi mældra para.

Hafna skal  $H_0$  ef  $F > F_{1-\alpha,(1,N-2)}$ .

Sé núlltilgátunni hafnað er  $\beta_1$  frábrugðið núlli.

Petta tilgátupróf er illframkvæmanlegt í höndunum en má reikna á einfaldan hátt í öllum helstu tölfræðiforritum.